

DOCUMENTACIÓN INTERNA

YT-AGENT-AI — Reporte de Contenido

App web que analiza videos de YouTube: transcribe el audio con **AssemblyAI** y genera un **reporte de contenido estructurado** con **Google Gemini**. Interfaz **Streamlit** + API REST **Django**.

gemini-3.5-flash-lite

POST /api/generate-report/

Clean Architecture

Docker

Descripción general

YT-AGENT-AI nació para traducir letras de canciones y evolucionó a un nuevo propósito: al ingresar una URL de YouTube, descarga el audio, lo transcribe y produce un reporte de contenido con 5 secciones (temas, argumento, opiniones, datos clave y conclusión).

Propósito actual

URL de YouTube → descarga de audio → transcripción (AssemblyAI) → reporte estructurado (Gemini) → persistencia en PostgreSQL → Streamlit / REST.

API Keys

La clave de AssemblyAI (AAI_API_KEY) vive en el servidor vía `.env`. La clave de Gemini la provee cada usuario en el sidebar de Streamlit o en el payload REST (`gemini_api_key`); no va en el `.env`.

Flujo de ejecución

- 1 Entrada.** Usuario provee URL de YouTube y su API Key de Gemini.
- 2 Descarga.** YouTubeService obtiene título y descarga video/audio a media/ con yt-dlp.
- 3 Transcripción.** TranscriptionService envía el audio a AssemblyAI y guarda el texto.
- 4 Análisis.** AnalysisService fragmenta la transcripción (chunks de 8000, máx. 30000) y genera el reporte con Gemini, con fallback entre modelos por cuota.
- 5 Persistencia.** Resultado guardado en `translationPost` vía Django ORM.
- 6 Visualización.** Reporte en Streamlit con botón de descarga en PDF, más video/audio.

Stack tecnológico

Componente	Tecnología	Versión
Backend	Django	4.1
Frontend	Streamlit	1.33.0
Transcripción	AssemblyAI	0.36.0
IA	Google Gemini	gemini-3.5-flash-lite
Descarga	yt-dlp	2025.9.26
PDF	fpdf2	2.7.9
Base de datos	PostgreSQL (Neon Cloud)	—
Contenedores	Docker + Compose	3.8

Estructura de directorios

TEXT

```
Backend/
├─ app.py                # Streamlit UI +
generate_report_pdf()
├─ manage.py            # Punto de entrada Django
├─ cleanup_media.py     # Limpieza de temporales (>5 min)
├─ crontab              # Cron cada 5 min
├─ requirements.txt     # google-generativeai, fpdf2, ...
├─ translation_generator_app/
│   ├─ services/        # youtube, transcription, analysis
│   ├─ serializers/     # validación del payload
│   ├─ views/           # ContentAnalysisView
│   ├─ exceptions.py    # AnalysisException, etc.
│   ├─ models.py        # translationPost
│   └─ urls.py          # /api/generate-report/
├─ ai_translation/      # settings, urls, wsgi, asgi
├─ media/               # videos/audio temporales
└─ docs/                # ARCHITECTURE, KEY_COMPONENTS,
                        # GIT_REORGANIZATION_MANUAL,
                        # PROYECTO_STATE, docs.html
```

Componentes principales

Servicios

YouTubeService

Extracción de título y descarga con yt-dlp (headers anti-bot).

`get_title``download_video_and_audio`

TranscriptionService

Sube audio a AssemblyAI y devuelve texto crudo.

`transcribe_audio`

AnalysisService

Reporte de 5 secciones con Gemini + fallback por cuota.

`generate_report`

`_try_with_fallback`

`_chunk_text`

Interfaz Streamlit (app.py)

Contenedor ligero sin lógica de negocio: importa servicios directamente, usa `st.session_state`, captura excepciones personalizadas y ofrece descarga del reporte en PDF vía `generate_report_pdf()`.

Excepciones

Base

`TranslationGeneratorException`

Específicas

`YouTubeDownloadException`

`TranscriptionException`

`AnalysisException`

`InvalidDataException`

Base de datos

Modelo `translationPost`: `youtube_title`, `youtube_link`, `generated_content` (reporte), `created_at`. Escritura al final del proceso exitoso.

Reporte de contenido (5 secciones)

1 Temas principales tratados.

2 Argumento / resumen narrativo.

3 Opiniones o puntos de vista.

4 Datos o hechos clave.

5 Conclusión / veredicto final.

API REST

POST /api/generate-report/

JSON — REQUEST

```
{
  "link": "https://youtube.com/watch?v=...",
  "gemini_api_key": "AI..."
}
```

JSON — RESPONSE 200

```
{
  "report": "Reporte de contenido...",
  "title": "Título del Video",
  "original_transcription": "Texto original...",
  "transcription_file": "/ruta/al/transcript.txt"
}
```

Errores

400 datos inválidos · 500 descarga/transcripción/análisis. Cada etapa tiene su excepción y mensaje específico.

Cambios recientes

Aspecto	Antes	Ahora
Propósito	Traducir canciones	Reporte de contenido
IA	OpenAI	Google Gemini
Endpoint	/api/generate-translation/	/api/generate-report/
Servicio	TranslationService	AnalysisService
Salida	Versos traducidos	Reporte + PDF

Fallback por cuota

gemini-3.5-flash-lite → gemini-3.1-flash-lite → gemini-2.5-flash-lite → gemini-2.5-flash → gemini-3-flash → gemini-3.7-flash → gemini-3.8-flash → gemini-3.5-flash → gemini-3.6-flash → gemini-flash-latest → gemma-4-26b / gemma-4-31b. Retries ante 429/RESOURCE_EXHAUSTED y 404.

Configuración del entorno

```
INI - .ENV (SERVIDOR)

# AssemblyAI - transcripción (servidor, nunca se pide al usuario)
AAI_API_KEY="..."

# NOTA: la API key de Google Gemini NO va en el .env.
# Cada usuario la ingresa en el sidebar de Streamlit
# o en el payload REST (gemini_api_key).

# Base de Datos (Neon Cloud PostgreSQL)
DB_NAME=neondb
DB_USER=neondb_owner
DB_HOST=...

# Django
SECRET_KEY=...
DEBUG=True
```

Despliegue

```
BASH

docker-compose up --build          # ambos servicios
docker compose build --no-cache backend # tras cambios en
requirements
docker compose restart backend frontend # tras cambios de código
```

Frontend (Streamlit): `http://localhost:8501` · Backend API:
`http://localhost:8000` . Ambos montan `./media` ; solo el backend corre `crond` .

Mantenimiento

`cleanup_media.py` borra archivos de `media/` con más de 5 minutos
(`AGE_LIMIT_SECONDS = 300` , por `mtime`). El cron lo ejecuta cada 5 minutos:

CRON

```
*/5 * * * * python /backend/cleanup_media.py >> /var/log/cron.log 2>&1
```

Nota

Tiempo real de borrado: 5–10 min tras la creación. Requiere el contenedor backend activo (es el único que inicia crond).

Preguntas frecuentes

¿Qué modelo de Gemini se usa?

Primario `gemini-3.5-flash-lite` (500 RPD) con cadena de fallback mapeada por cuota.

¿Por qué el reporte sale en español aunque el video sea en otro idioma?

El prompt instruye responder exclusivamente en español; no hay traducción, solo análisis.

¿Por qué falla con “video muy largo”?

La transcripción se trunca a 30000 caracteres y se procesa en chunks; si Gemini excede el timeout o la cuota diaria, se sugiere un video más corto o reintentar.

¿Para qué sirve la API key del .env si Gemini se pide en el frontend?

En el `.env` solo vive `AAI_API_KEY` (AssemblyAI), porque la transcripción nunca se pide al usuario. Gemini sí se pide por usuario.

¿Dónde está el historial Git?

Ver `docs/GIT_REORGANIZATION_MANUAL.md` (main reemplazada por feature/deploy, respaldo en main-old).

Checklist de verificación

1. `AnalysisService` importa en backend y frontend.
2. `google-generativeai==0.8.4` y `fpdf2==2.7.9` instalados en imágenes.
3. Endpoint `/api/generate-report/` responde.
4. Botón **Download Report (PDF)** visible tras generar el reporte.
5. `GEMINI_API_KEY` fuera del `.env` ; documentado en README y `PROYECTO_STATE`.
6. PDF pandoc (`PROYECTO_STATE.pdf`) y PDF diseñado generados.